

INFORMACIÓN


CUÁNTICA

CLASE 2

PROF. DR. ANDRÉS TANUS CESÁRIO

([ANDRETANUS@GMAIL.COM](mailto:ANDRETANUS@GMAIL.COM))

PROF. DR. TEÓFILO VARGAS



## 2. TEORÍA CLÁSICA DE LA INFORMACIÓN


### REGRESANDO

	INFORMACIÓN	CODIFICACIÓN	COMUNICACIÓN	DECODIFICACIÓN/MEDICIÓN
CLÁSICO		$m \text{ bits}$ $100110101\dots$ $\downarrow$ $f(m)$	GRABACIÓN $f'(m)$ ↓ FIDELIDAD TRANSMISIÓN $f''(m)$ CANAL CLÁSICO →	$g(f'(m))$ $\downarrow ?$ $m'' \approx m$
CUÁNTICO		$100110101\dots$ CODIFICADO EN UN SISTEMA FÍSICO $p_m$ $\epsilon(p_m)$	- GRABACIÓN: LÍMITE DE LANDAUER $\epsilon'(p_m)$ - TRANSMISIÓN: CAPACIDAD DE UN CANAL CUÁNTICO $I(p_m)$	MEDICIÓN $p_m' \approx p_m$

## 2. TEORÍA CLÁSICA DE LA INFORMACIÓN


### 2.1 REPASO DE LA TEORÍA DE LA PROBABILIDAD

#### TEOREMA DE BAYES



- EL UNIVERSO  $\Omega$ : TODOS LOS RESULTADOS POSIBLES.
- $P(\Omega) = \frac{|\Omega|}{|\Omega|} = 1$ , ADÓNDE  $| \cdot |$  SIGNIFICA ÁREA (UNA MEDIDA)
- $A \cap B$  ES LA PARTE ADÓNDE A Y B OCURREN
- $P(B) = \frac{|B|}{|\Omega|}$  y  $P(A) = \frac{|A|}{|\Omega|}$

- $P(A \cap B) = \frac{|A \cap B|}{|\Omega|}$
  - PERO CUAL ES LA PROBABILIDAD DE A ocurrir, YA QUE B YA HA OCURRIDO
- $$P(A|B) = \frac{|A \cap B|}{|B|} = \frac{\frac{|A \cap B|}{|\Omega|}}{\frac{|B|}{|\Omega|}} = \frac{P(A \cap B)}{P(B)} \Rightarrow P(A \cap B) = P(A|B) \cdot P(B)$$



LA MISMA IDEA

$$P(B|A) = \frac{P(A \cap B)}{P(A)} \Rightarrow P(A \cap B) = P(B|A) \cdot P(A)$$

$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$

## CUANTIFICACIÓN DE LA INFORMACIÓN

- CÓMO SE CUANTIFICA LA INFORMACIÓN?
- SHANNON (1948) DESARROLLÓ LA 1<sup>a</sup> TEORÍA EXITOSA DE LA INFORMACIÓN (P/BELL LAB.)
- SU TEORÍA SE USA P/ BIOLOGÍA, SOCIOLOGÍA, ECONOMÍA, GÉ.
- SHANNON MODELO INFORMACIÓN COMO EVENTOS QUE OCURREN CON CIERTAS PROBABILIDADES.
- CON ESTO, EL POSTULÓ LOS SIGUIENTES REFINAMIENTOS QUE CUALQUIER MEDIDA DE INFORMACIÓN DEBE POSSEÑ:
- 1. LA CANTIDAD DE INFORMACIÓN DE UN EVENTO X DEBE DEPENDER SOBRE SU PROBABILIDAD  $P(X)$ . CUANTO MÁS SORPRENDIDOS ESTAMOS POR UN EVENTO QUE OCURRE, MÁS INFORMACIÓN LLEVA ESTE EVENTO.

EJEMPLOS: CAÍDA DE NIEVE EN EL ÁNDICO VERSUS EN LIMA.

2. LA FUNCIÓN  $I(p)$  DEBE SER CONTINUA EN  $p$  (IGNORANDO TRANSICIONES DE FASE Y ALGUNAS ANOMALÍAS).  $I(p+dp) \approx dI(p)$ . TIENE POCO SENTIDO QUE SI LA PROBABILIDAD DE UN EVENTO NOS DEJE MUCHO MÁS SORPRENDIDOS CUANDO EL EVENTO OCURRA.

3. ADITIVIDAD:  $I(p(x,y)) = I(p(x)) + I(p(y))$  SI LOS EVENTOS  $X$  Y  $Y$  SON INDEPENDIENTES, ES DECIR, SI  $p(x,y) = p(x)p(y)$

SHANNON MOSTRÓ QUE LAS 3 CONDICIONES IMPLICAN QUE

$$I(p(x)) = \log_2\left(\frac{1}{p(x)}\right) = -\log_2(p(x))$$

- LA ENTROPIA DE SHANNON APARECE COMO LA INFORMACIÓN PROMEDIA NEURÉTICA PARA ESPECIFICAR  $X$ , CUANDO EL RECEPTOR RECIBE  $P(X)$ .
- MIDE DE MANERA EQUIVALENTE, LA CANTIDAD DE INCERTIDUMBRE REPRESENTADA POR  $P(X)$ .
- EN NUESTRO CONTEXTO, EQUIVALE A LA CANTIDAD MÍNIMA EN BITS QUE DEBEN TRANSMITIRSE PARA DETERMINARMOS LA VARIABLE  $X$ , PERO ESTE CONCEPTO DEBERÍA SER CONECTADO CON LOS TEOREMAS DE COMPRESIÓN Y CODIFICACIÓN DE DATOS.
- VALOR ESPERADO O VALOR PROMEDIO DE UNA FUNCIÓN  $g$  DE UNA VARIABLE ALÉATORIA  $X$  QUE OCURRE CON PROBABILIDAD  $P(X)$

$$E_{P(X)}(g(x)) = \sum_x p(x) g(x)$$

## ENTROPIA DE SHANNON


$$H(x) = E_{p(x)}(I(p(x))) = \sum_x p(x) \log_2\left(\frac{1}{p(x)}\right) = -\sum_x p(x) \cdot \log_2(p(x))$$

$$H(x) = -\sum_{x=1}^n p(x) \cdot \log_2(p(x))$$

- CUANTIFICA CUANTA INFORMACIÓN ES NECESARIA, EN PROMEDIO, PARA CODIFICAR  $n$  BITS DE INFORMACIÓN.
- VAMOS SUPONER QUE TENEMOS UN ALFABETO BINARIO  $X = \{0, 1\}$   
CON  $p(0) = (1-p)$  y  $p(1) = p$
- LA ENTROPIA DE SHANNON DE  $p(x)$  ES :

$$H(X) = - \sum_{x=0}^1 p(x) \cdot \log_2(p(x)) = -p(0) \log_2(p(0)) - p(1) \log_2(p(1))$$

$$H(X) = -(1-p) \cdot \log_2(1-p) - p \cdot \log_2(p)$$



- SUPONGAMOS QUE ALICE JUEGA UNA MONEDA SESGADA  $n$  VECES y QUIERE ENVIAR A BOB EL RESULTADO DEL JUEGO.

- DE EXPERIMENTOS PREVIOS SABEN QUE

$$\begin{cases} P\left(\begin{array}{c} \text{UN NUEVO SOL} \\ \text{2002} \end{array}\right) = 0,75 \rightarrow P(0) = 0,75 \\ P\left(\begin{array}{c} \text{OJO} \\ \text{CENAVIL DE RESERVA} \\ \text{2002} \end{array}\right) = 0,25 \xrightarrow{\text{y}} P(1) = 0,25 \end{cases}$$

- SI ALICE JUEGA  $n = 1$  MILLÓN DE VECES,  $h_0 \approx 750000$  Y  $h_1 \approx 250000$
- A MEDIDA QUE  $n \rightarrow \infty$ , ELLOS PUEDEN ESTAR AUN MÁS SEGUNOS QUE VAN A RECIBIR UNA SECUENCIA CON NÚMEROS  $h_0 = 0,75 \cdot h$  Y  $h_1 = 0,25 \cdot h$ .
- ESTA SECUENCIA SE LLAMA **SECUENCIA TÍPICA**

- AHORA VAMOS A SUPONER QUE VAMOS A ENVIAR UNA CANTIDAD  $n$  GRANDE.
- LAS SECUENCIAS TÍPICAS VAN A TENER, APROXIMADAMENTE  
EN EL EJEMPLO  $p = 0,25$ 

$$\begin{cases} n_0 \approx n \cdot p(0) = n \cdot (1 - p) \\ n_1 \approx n \cdot p(1) = n \cdot p \end{cases}$$
- EL NÚMERO DE SECUENCIAS DISTINTAS ES DEL ORDEN DEL COEFICIENTE BINOMIAL DE NEWTON:

NÚMERO       $N \approx \binom{n}{n \cdot p},$

- USANDO LA APROXIMACIÓN DE STIRLING,  $\ln(n!) \approx n \cdot \ln n - n$

$$\log \binom{n}{n \cdot p} = \log \left( \frac{n!}{n p! (n - np)!} \right) = \log \left( \frac{n!}{n p! n (1-p)!} \right) \approx$$

$$\log \binom{n}{n \cdot p} \approx n \cdot \log(n) - n - [np \cdot \log(np) - np + n(1-p) \cdot \log(n(1-p)) - n(1-p)]$$

$$\log_2(N) \approx n [-p \cdot \log_2(p) - (1-p) \cdot \log_2(1-p)] \approx n \cdot H(x)$$

$N \approx 2^{nH(x)}$

SECUENCIAS DE TAMAÑO  $\approx n H(x)$

- CUANDO  $n \rightarrow \infty$   $P(\text{SECUENCIA TÍPICA}) \rightarrow 1$
- CON UNA PEQUEÑA PROBABILIDAD, LA MONEDA PRODUCIRÁ UNA SECUENCIA ATÍPICA, EN CUYO CASO LA COMPRESIÓN FALLA.
- POR ESTA RAZÓN, ESTA COMPRESIÓN ES LLAMADA DE COMPRESIÓN SIN RUÍDO.
- EN GENERAL, EL OBJETIVO DE LA COMPRESIÓN DE DATOS ES PARA QUE 2 PARES (ALICE Y BOB), ES DECIR, A Y B SE COMUNICEN EN UN CANAL INICIALMENTE SIN RUÍDO.
- LA COMPRESIÓN DE DATOS FUNCIONA COMO UN GRAN BLOQUE DE INFORMACIÓN QUE SE PUEDE DIVIDIR EN SECUENCIAS TÍPICAS (QUE CONTIENEN CARACTERES PROBABLES) Y SECUENCIAS ATÍPICAS QUE CONTIENEN SECUENCIAS DE CARACTERES IMPROBABLES.

- SEA  $X^n$  n MUESTRAS INDEPENDIENTES DE UNA VARIABLE ALEATORIA X Y SEA  $x_1; x_2; x_3; \dots; x_n$  UNA SECUENCIA DE VALORES OBTENIDOS DE  $X^n$ .
- $H(X) = E_{P(X)}(-\log(P(X)))$
- LA LEY DOS GRANDES NÚMEROS (VERSIÓN DÉBIL) NOS DICE QUE PARA CADA  $\delta > 0$  Y  $\varepsilon > 0$ , EXISTE UN  $n$  (SUFICIENTEMENTE GRANDE), TAL QUE, CON UNA PROBABILIDAD DE AL MENOS  $1 - \varepsilon$ , UNA SECUENCIA  $\varepsilon$ -típica  $x_1; \dots; x_n$  OCURRA SATISFAENDO

$$\frac{-n(H(X)+\delta)}{2} < P(x_1, x_2, \dots, x_n) < \frac{-n(H(X)-\delta)}{2}$$

$$\text{DE } \sum_{i=1}^{-h(H(x)+\delta)} p(x_1, x_2, \dots, x_n) < 1$$

$$|N(\varepsilon, \delta)| \leq 2^{n(H(x)+\delta)}$$

$n(H(x)+\delta)$  bits son suficientes para un error máximo de  $\varepsilon$ .

### PROPIEDADES DE LA ENTROPIA DE SHANNON

- LA ENTROPIA DE SHANNON ES NO NEGATIVA

$$H(x) \geq 0$$

COMO  $0 \leq p(x) \leq 1$ , ENTONCES

$$H(x) = -\sum p(x_i) \log \left( \frac{1}{p(x_i)} \right) \geq 0$$

## DESIGUALDAD DE JENSEN P/ FUNCIONES CONCAVAS

SEA  $X$  UNA VARIABLE ALEATORIA Y  $f$  UNA FUNCIÓN ESTRICTAMENTE CONCAVA, ENTONCES

$$E_{p(x)}(f(x)) \leq f(E_{p(x)}(x))$$

### PRINCIPIO DE MAXENT

$$\begin{aligned} \text{SEA } f\left(\frac{1}{p(x)}\right) &= \log\left(\frac{1}{p(x)}\right) \\ f\left(\frac{1}{p(x)}\right) &= I(p(x)) \end{aligned}$$

$$E_{p(x)}(f(x)) \leq f(E_{p(x)}(x))$$

$$\sum_{x=1}^n p(x) \cdot \log\left(\frac{1}{p(x)}\right) \leq \log\left(\sum_{x=1}^n p(x)\left(\frac{1}{p(x)}\right)\right)$$

$$H(p(x)) \leq \log n$$

EL VALOR MÁXIMO OCURRE P/ EL VECTOR  $p(x) = \frac{1}{n} \ \forall n.$

## INFORMACIÓN MÚTUA DE SHANNON Y OTRAS ENTROPIAS

- ENTROPIA RELATIVA (DIVERGENCIA DE KULLBACK-LEIBLER)  
ES UNA MEDIDA DE COMO UNA DISTRIBUCIÓN P ES DIFERENTE DE UNA OTRA DISTRIBUCIÓN DE NEFGRENCIÓN Q

$$D_{KL}(P||Q) = \sum_x P(x) \log\left(\frac{P(x)}{Q(x)}\right)$$

MIDE LA SIMILITUD ENTRE P y Q.

- UNA INTERPRETACIÓN DE  $D_{KL}$  ES UNA "DISTANCIA" ENTRE 2 DISTRIBUCIONES, AUNQUE NO SEA UNA MÉTRICA ( $D_{KL}(P||Q) \neq D_{KL}(Q||P)$  EN GENERAL). TAMBIÉN NO SATISFACE LA DESIGUALDAD TRIANGULAR AUNQUE EXISTA UNA DESIGUALDAD "DEL TIPO DE PITAGÓRAS"  
GENERALIZADA.

- ENTROPÍA CONJUNTA  $H(X, Y)$ , DONDE  $X, Y = X \cup Y$

QUE MIDE LA INFORMACIÓN COMBINADA EN 2 (O MÁS) VARIABLES ALEATORIAS

$$H(X, Y) = - \sum_x \sum_y p(x, y) \log_2(p(x, y))$$

$$H(X, Y) \geq 0$$

$$H(X, Y) \geq \max \{ H(X), H(Y) \}$$

COVER Y THOMAS, 1995

RECORDE QUE

LAS DISTRIBUCIONES MARGINALES SON:

$$P(X) = \sum_y p(x, y)$$

$$P(Y) = \sum_x p(x, y)$$

$$\sum_x P(X) = \sum_x \sum_y p(x, y) = 1$$

$$\sum_y P(Y) = \sum_y \sum_x p(x, y) = 1$$

ENTROPIA CONDICIONAL:  $H(X|Y)$  y  $H(Y|X)$

MIDE LA INFORMACIÓN CONTENIDA EN UNA VARIABLE ALÉATORIA DADO QUE SE CONOCE EL RESULTADO DE OTRA VARIABLE ALÉATORIA

$$H(Y|X) = - \sum_{x,y} p(x,y) \log(p(y|x)) = - \sum_{x,y} p(x,y) \log\left(\frac{p(x,y)}{p(x)}\right)$$

$$H(Y|X) = - \sum_{x,y} p(x,y) \log\left(\frac{p(x,y)}{p(x)}\right)$$

$$H(X|Y) = - \sum_{x,y} p(x,y) \log(p(x|y)) = - \sum_{x,y} p(x,y) \log\left(\frac{p(x,y)}{p(y)}\right)$$

$$H(X|Y) = - \sum_{x,y} p(x,y) \log\left(\frac{p(x,y)}{p(y)}\right)$$

## INFORMACIÓN MUTUA      $I(X:Y)$


MIDE LA "CORRELACIÓN" ENTRE 2 VARIABLES ALEATORIAS, EN TÉRMINOS DE CUANTO CONOCIMIENTO DE UNA VARIABLE ALEATORIA REDUCE LA INFORMACIÓN OBTENIDA AL APrender LA OTRA VARIABLE.

## MIDE LA DEPENDENCIA ENTRE 2 VARIABLES

$$I(X:Y) = \sum_x \sum_y p(x,y) \log \left( \frac{p(x,y)}{p(x) \cdot p(y)} \right)$$

- Si  $p(x,y) = p(x) \cdot p(y)$  (VARIABLES INDEPENDIENTES),  $I(X:Y) = 0$
- $I(X:Y) \geq 0$        $y$        $I(X:Y) = I(Y:X)$

## PROPIEDADES Y RELACIONES DE LAS ENTROPIAS



CONDICIONAL  
DISMINUYE LA  
ENTROPIA

$$H(X) \geq H(X|Y) > 0$$

$$H(Y) \geq H(Y|X) > 0$$

LA IGUALDAD  
OCURRE CUANDO  
X Y Y SON  
INDEPENDIENTES


$$H(X,Y) \leq H(X) + H(Y)$$

$$I(X:Y) = H(X) - H(X|Y)$$

$$I(X:Y) = H(Y) - H(Y|X)$$

$$I(X:Y) = H(X) + H(Y) - H(X,Y)$$


$$I(X:Y) = H(X,Y) - H(X|Y) - H(Y|X)$$



### CAPACIDAD DE UN CANAL RUIDOSO

- CUANDO ALICE TRANSMITE UN MENSAJE A BOB, ELLA ENVÍA UNA CADENA DE BITS QUE PUEDE SER CONSIDERADA COMO UNA VARIABLE ALÉATORIA  $X$ .
- SI EL CANAL ES RUIDOSO, ESTE SEÑAL SE CAMBIARÁ DEBIDO A ERRORES


- EL MODELO MATEMÁTICO DE UN PROTOCOLO DE COMUNICACIÓN ES



- $P(Y|X)$  ES COMO MODELAMOS EL CANAL RUIDOSO
- SI LA CORRELACIÓN DE  $Y$  CON  $X$  ES CERO, BOB NO NECESA EL MENSAJE DE ALICE.

ALICE INTENTA  
ENVÍAR  $X$  P/

BOB



SIN EMBAÑO,  
BOB RECIBE  $Y$   
POR EL RUÍDO DEL CANAL

## TEOREMA DE SHANNON

- EL TEOREMA DE SHANNON MUESTRA CÓMO CALCULAR LA CAPACIDAD DE UN CANAL CLÁSICO A PARTIR DE LA DESCRIPCIÓN ESTADÍSTICA DE UN CANAL RUIDOSO CON UNA CAPACIDAD  $C$ , CON INFORMACIÓN TRANSMITIDA A UNA TASA  $R$ .
- SI  $R < C$ , EXISTE UNA TÉCNICA DE CODIFICACIÓN QUE PERMITE QUE LA PROBABILIDAD DE ERROR SE HAGA ARBITRARIAMENTE PEQUEÑA.
- SI  $R > C$ , LA PROBABILIDAD DE ERROR AUMENTA SIN LÍmite CUANDO  $R$  AUMENTA.
- UNA FUENTE  $X$  CON ENTROPIA  $H(X)$  GENERA  $\approx 2^{nH(X)}$  SECUENCIAS TÍPICAS EN  $n$  PASOS. EL NÚMERO DE MENSAJES ÚTILES (SIN REDUNDANCIA) ES
$$2^{n(H(X) - H(X|Y))}$$

$$\text{COMO} \begin{cases} I(X:Y) = H(X) - H(X|Y) \\ I(X:Y) = H(Y) - H(Y|X) \end{cases} \in N \approx 2^{hI(X:Y)}$$

CAPACIDAD DE UN CANAL


$$C = \sup_{\substack{P(x) \\ X}} \{I(X:Y)\}$$

### ALGUNAS MEDIDAS IMPORTANTES

#### FIDELIDAD

$$F(\vec{P}, \vec{Q}) = \sum_i \sqrt{p_i q_i}$$

c/  $\vec{P} = (p_1, p_2, \dots, p_N)^T$   
 $\vec{Q} = (q_1, q_2, \dots, q_N)^T$



$$\left\{ \begin{array}{l} F(\vec{P}, \vec{Q}) = \sqrt{\vec{P}} \cdot \sqrt{\vec{Q}} = |\sqrt{\vec{P}}| \cdot |\sqrt{\vec{Q}}| \cos \theta = \cos \theta \\ \text{porque } \sum_x (N_{Px})^2 = \sum_x (N_{Qx})^2 = 1 \end{array} \right.$$

LA INTERPRETACIÓN DE LA FIDELIDAD ES EL PRODUCTO ESCALAR ENTRE LOS VECTORES  $\sqrt{\vec{P}}$  Y  $\sqrt{\vec{Q}}$  EN UNA ESFERA UNITARIA

### DISTANCIA $\ell_1$

$$d(\vec{P}, \vec{Q}) = \frac{1}{2} \sum_i |p_i - q_i|$$

ES EL EQUIVALENTE A LA DISTANCIA DE LA TMAZA

$$2.2) \quad \vec{P} = (p, 1-p) \quad d(\vec{P}, \vec{Q}) = \frac{1}{2} \left\{ |p - q| + |(1-p) - (1-q)| \right\}$$

$$d(\vec{P}, \vec{Q}) = \frac{1}{2} \left\{ |p - q| + |1-p + q| \right\} = \frac{1}{2} \left\{ 2|p - q| \right\}$$

$$d(\vec{P}, \vec{Q}) = |p - q|$$

DISTANCIA  $\ell_2$  (NORMA EUCLÍDEANA)      TEOREMA DE PITÁGORAS

$$d_2(p, Q) = \|\vec{P} - \vec{Q}\|_2 = \sqrt{(p_1 - q_1)^2 + \dots + (p_n - q_n)^2}$$

DISTANCIA  $\ell_\infty$

$$d_\infty(p, Q) = \lim_{k \rightarrow \infty} \left[ \sum_i |p_i - q_i|^k \right]^{\frac{1}{k}} = \max_i (|p_i - q_i|)$$

## DISTANCIA DE BHATTACHARYYA

(UNA DEFINICIÓN POSIBLE):

$$d_{\text{BHATTACHARYYA}} = - \ln [F(p, q)] = - \ln \left[ \sum_i \sqrt{p_i q_i} \right]$$

## DIVERGENCIA DE JENSEN-SHANNON J

$$J(p||q) = \frac{1}{2} D(p||m) + \frac{1}{2} D(q||m), \quad \text{CON} \quad m = \frac{p+q}{2}$$

## DISTANCIA DE WOOTTERS

$$D_W = \arccos(F)$$

## DISTANCIA DE HELLINGER

$$H(P, Q) = \frac{1}{\sqrt{n}} \| \sqrt{P} - \sqrt{Q} \|_2 = \frac{1}{\sqrt{n}} \sqrt{\sum_i (\sqrt{p_i} - \sqrt{q_i})^2}$$

ES INTERESANTE MIRAR QUE

$$H^2(P, Q) = \frac{1}{2} \sum_i (\sqrt{p_i} - \sqrt{q_i})^2$$

$$H^2(P, Q) = \frac{1}{2} \sum_i p_i - 2 \sqrt{p_i q_i} + q_i$$

$$H^2(P, Q) = \frac{1}{2} \sum_i (p_i + q_i) - \frac{1}{2} \sum_i \cancel{(\sqrt{p_i} + \sqrt{q_i})}$$

$$F(P, Q) = \sum_i \sqrt{p_i q_i} = 1 - H^2(P, Q)$$

$$\frac{1}{2} \sum_i (p_i + q_i) = 1$$

$$\frac{1}{2} \sum_i p_i + \frac{1}{2} \sum_i q_i = 1$$

## PROBABILIDADES "NEGATIVAS" - INTERFERENCIA

Quantum mechanics permits the cancellation of possibilities.

Nick Herbert, Quantum Reality.

- COMO HEMOS VISTO, HAY VARIOS TIPOS DE NORMAS QUE INDUCEN VARIAS DISTANCIAS DIFERENTES.
- HAY LA NORMA  $\|\vec{P}\|_1 = \sum_i |p_i| = \sum_i p_i = 1$   $\rightarrow d(\vec{P}, \vec{Q}) = \frac{1}{2} \sum_i |p_i - q_i|$   

↓  
NORMA DE LA TECNICA DE PROBABILIDADES

LA DISTANCIA  $\|\cdot\|_1$  O LA  
NORMA DE LA TAZA
- OTRA NORMA POSIBLE ES LA NORMA EUCLIDIANA  
 $\|\vec{P}\|_2 = \sqrt{\sum_i p_i^2}$   $\rightarrow d_2(P, Q) = \|\vec{P} - \vec{Q}\|_2 = \sqrt{(p_1 - q_1)^2 + \dots + (p_n - q_n)^2}$   
LA DISTANCIA  $\|\cdot\|_2$  ES EL TEOREMA DE PITAGORAS
- CUALES SON LAS CONSECUENCIAS SI INTENTAMOS CONSTRUIR UNA "OTRA" TEORIA DE PROBABILIDADES BASADA EN LA NORMA  $\|\cdot\|_2$ ?

- VOY A INTENTAR CONVENCERLOS QUE ES LA MECÁNICA CUÁNTICA QUE SUGiere NECESSARIAMENTE.
  - LA UNIDAD BÁSICA DE LA INFORMACIÓN ES EL BIT
- bit probabilísticos  $\begin{cases} P(0) = p \\ P(1) = 1-p \end{cases}$
- $$\vec{P} = (p, 1-p)^T; \|\vec{P}\|_1 = 1$$
- VAMOS CAMBIAR LA NORMA  $l_1$  POR  $l_2$  Y MANTENER LOS VECTORES DE PROBABILIDAD
- $\vec{P} = (\alpha, \beta)^T \in \mathbb{R}^2$
- CON LA NORMA  $l_2$ , NO PODEMOS ASIGNAR DIRECTAMENTE UNA PROBABILIDAD PARA REALIZAR UN EXPERIMENTO Y OBTENER UN RESULTADO "0", POR EJEMPLO, NECESITAMOS DEFINIR ALGO COMO UNA **AMPLITUD DE PROBABILIDADES**

- ESTAS AMPLITUDES  $\alpha$  y  $\beta$ , EN EL CASO BINARIO, SON TALES QUE

$$\begin{cases} P(\alpha) = \alpha^2 \\ P(\beta) = \beta^2 \end{cases} \quad \vec{P} = (\alpha, \beta)^T \in \mathbb{R}^2$$

- SI INTENTAMOS USAR LA NORMA  $\| \cdot \|_1$ , PARA MEDIR ESTE VECTOR, VAMOS A OBTENER UN VECTOR NO-NORMALIZADO, PORQUE  $\alpha + \beta \neq 1$ . (EN GENERAL  $\alpha + \beta \in \mathbb{C}$ )

- SÍN EMBARGO, COMO ESTA LEVÍA ES MEDIDA POR LA NORMA  $\| \cdot \|_2$ , Y NO LA NORMA  $\| \cdot \|_1$ ,

$$\| \vec{P} \|_2 = \sqrt{\sum_i P_i^2} = \sqrt{\alpha^2 + \beta^2} = \sqrt{P(\alpha) + P(\beta)} = \sqrt{1} = 1$$

- ENDOÑCES, POR QUÉ NO OLVIDAN LAS AMPLITUDES  $\alpha$  y  $\beta$  Y DESCRIBIR EL BÍT CUÁNTICO SOLO POR SUS PROBABILIDADES?

- LA DIFERENCIA ES COMO SE TRANSFORMA ESTE VECTOR CUANDO REALIZAMOS OPERACIONES SOBRE EL.
- LAS MATRICES ESTOCÁSTICAS SON LAS MATRICES QUE PRESERVAN LA NORMA 1, INALTERAN Y SON ESTAS TRANSFORMACIONES QUE LOS BITS CLÁSICOS Y ESTADOS DE LA TEORÍA DE PROBABILIDAD EN GENERAL

$$\|\vec{p}\|_1 = 1$$

SEA S UNA MATRIZ ESTOCÁSTICA (SUS COLUMNAS O LÍNEAS SUMAN UNO)

PROVEA P/  $\dim(S) = 2$

$$S = \begin{pmatrix} p & 1-q \\ 1-p & q \end{pmatrix} \quad c/ \quad \begin{cases} 0 \leq p \leq 1 \\ 0 \leq q \leq 1 \\ 0 \leq \alpha \leq 1 \end{cases}$$

$$\vec{p} = \begin{pmatrix} \alpha \\ 1-\alpha \end{pmatrix}$$

$$S \cdot \vec{P} = \begin{pmatrix} p & 1-q \\ 1-p & q \end{pmatrix} \cdot \begin{pmatrix} s \\ 1-s \end{pmatrix}_{2 \times 1} = \begin{pmatrix} ps + (1-q)(1-s) \\ q(1-s) + (1-p)s \end{pmatrix}_{2 \times 1}$$

$$\|S \cdot \vec{P}\|_1 = ps + (1-q)(1-s) + q(1-s) + (1-p)s = \cancel{ps} + 1 - \cancel{s} - \cancel{q} + \cancel{q} + \cancel{q} - \cancel{q}s + \cancel{s} - \cancel{p}s = 1$$

- PERO, EN LA NORMA  $\ell_2$ , LA MATRIZ MÁS GENERAL QUE SIEMPRE MAPERA UN VECTOR NORMALIZADO EN ESTA NORMA ES UNA MATRIZ UNITARIA Y  $U^+U = UU^+ = \mathbb{I}$ .

$$\langle |\psi'\rangle^+ = (U|\psi\rangle)^+$$

$$\langle \psi' | = \langle \psi | U^+$$

- Si  $\| |\psi\rangle \|_2 = \sqrt{\langle \psi | \psi \rangle} = 1$


$|\psi'\rangle = U|\psi\rangle$  TAMBIÉN DEBE ESTAR NORMALIZADO

$$\| |\psi'\rangle \|_2 = \sqrt{\langle \psi' | \psi' \rangle} = \sqrt{\langle \psi | U^+ U | \psi \rangle} = \sqrt{\langle \psi | \mathbb{I} | \psi \rangle} = 1$$

- NUESTRA "TEORÍA DE PROBABILIDADES" DEFINIDA POR MEDIO DE LA NORMA  $\ell_2$  EVOLUCIONA POR MEJO DE MATRICES UNITARIAS. ESTO GENERA UN TIPO DE CANCELACIÓN DE LAS AMPLITUDES DE PROBABILIDAD.
- COMO EJEMPLO DE ESTE FENÓMENO, IMAGINA UN QUBIT INICIALMENTE EN EL ESTADO  $|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$  Y VAMOS USAR UNA "MONEDA" CUÁNTICA

$$U = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

LA EVOLUCIÓN  
ES DADA POR ESTE  
DIAGRAMA



VAMOS APLICAR U DOS VECES Y INTERPRETAMOS LOS RESULTADOS EN CADA PASO.

- COMO SE DISCUTIÓ ANTERIORMENTE, SUPONGAMOS QUE NUESTRO QUBIT ESTÁ INICIALMENTE EN  $|\Psi\rangle = |0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ .  $|1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$


- SI APLICAMOS  $U|\Psi\rangle = U|0\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$

$$P(|0\rangle) = \left| \frac{1}{\sqrt{2}} \right|^2 = \frac{1}{2} \quad y \quad P(|1\rangle) = \left| \frac{1}{\sqrt{2}} \right|^2 = \frac{1}{2}$$

- NECESITAMOS QUE CON ESTA NUEVA NORMA LAS AMPLITUDES NO SUMAN A 1:  $\left( \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} \neq 1 \right)$ .

- POR ESTA RAZÓN

$$\begin{aligned} \|\vec{p}\|_2 &= \sqrt{\sum_i p_i^2} = \sqrt{\alpha^2 + \beta^2} = \sqrt{P(\alpha) + P(\beta)} \\ &= \sqrt{1} = 1 \end{aligned}$$



$$|\Psi'\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$$

- PERO, OBSERVE QUE SI APLICAMOS U UNA VEZ MÁS, OBTENEMOS  $|1\rangle$  CON 100%. DE CERTEZA!
- PODRIAMOS PENSAR EN LA PRIMERA OPERACIÓN U COMO UN LANZAMIENTO DE UNA "MONEDA". DESPUÉS DE LA PRIMERA OPERACIÓN CUANDO, TENÍAMOS 2 CAMINOS DIFERENTES QUE SEGUIR.
- PERO, SI APLICAMOS 2 VECES UNA OPERACIÓN ALTERNATIVA PRODUCIRÍAMOS UN RESULTADO DETERMINISTA  $|1\rangle$ !

- ESTE ES EL FENÓMENO DE INTERFERENCIA.  
LOS CAMINOS NO OBSERVADOS QUE CONDUZEN AL RESULTADO  $|0\rangle$  INTERFIEREN DESTRUCTIVAMENTE Y CANCELAN ENTRE SI Y NO SON OBSERVADOS, MIENTRAS LOS CAMINOS P/  $|1\rangle$  INTERFIEREN CONSTRUCTIVAMENTE!

